Enabling People
Education for Future Generations

Curso de Inteligencia Artificial

Capítulo 4. Quiz

Para estudiantes

ⓒ2023 SAMSUNG. All rights reserved.

Samsung Electronics Corporate Citizenship Office holds the copyright of this document.
This document is a literary property protected by copyright law so reprint and reproduction without permission are prohibited.
To use this document other than the curriculum of Samsung Innovation Campus, you must receive written consent from copyright holder.

1. Pruebas de hipótesis

En una prueba de hipótesis utilizamos un nivel de significancia de 0.05. Si obtenemos un valor p de 0.03, ¿qué decisión debemos tomar?

A) Aceptar la hipótesis nula (H_0).

B) Rechazar la hipótesis nula (H_0).

Razonamiento: Si el valor p es menor o igual que α, pues se rechaza H_0. Aquí 0.03 < 0.05, asi que hay evidencia suficiente para rechazarla, tampoco se acepta H_0, como mucho “no se rechaza”.

C) No podemos tomar una decisión.

D) Rechazar la hipótesis alternativa (H_1).

2. Probabilidad binomial

Una familia tiene tres hijos. Suponiendo que cada hijo tiene un 50% de probabilidad de ser varón, independientemente de los demás, responde:

a) ¿Cuál es la probabilidad de tener exactamente dos hijos varones?

Primero, la probabilidad de una forma concreta de tener 2 varones, por ejemplo Varón-Varón-Mujer: 0.5 × 0.5 × 0.5 = 0.125.

Pero hay 3 formas de que pase: VVM, VMV, MVV. Ese “3” es lo que calcula C(3,2), que se lee “combinaciones de 3 en 2”: de 3 lugares, ¿de cuántas maneras eliges 2 para los varones?

Total: 3 × 0.125 = 0.375.

b) ¿Cuál es el número esperado (media) de hijos varones?

Media = n × p = 3 × 0.5 = 1.5

Si cada hijo tiene “mitad de chance” de ser varón y son 3 hijos, en promedio sale la mitad de 3. Si miles de familias tuvieran 3 hijos, el promedio de varones por familia sería 1.5.

c) ¿Cuál es la varianza del número de hijos varones?

Muestra tus cálculos:

Varianza = n × p × (1 − p) = 3 × 0.5 × 0.5 = 0.75

En la calculadora: 3 × 0.5 × 0.5 = → 0.75

Piensa en la varianza como “qué tan impredecible es”. Si p fuera 1 (todos los hijos siempre varones), la varianza sería 3 × 1 × 0 = 0, porque siempre saldrían 3 varones, sin sorpresas. Con p = 0.5 hay máxima incertidumbre.

3. Estandarización de variables

Si una variable aleatoria X sigue una distribución normal con media μ y desviación estándar σ, ¿cuál es la fórmula correcta para calcular su valor estandarizado Z?

A) $Z = (X - \mu) / \sigma$

B) $Z = (X - \mu) / \sigma^2$

C) $Z = (X + \mu) / \sigma$

D) $Z = (X - \sigma) / \mu$

4. Selección de una prueba estadística

Se realiza una encuesta a 100 personas para investigar si el nivel de satisfacción (satisfecho o no satisfecho) está relacionado con el género de los participantes.

¿Qué prueba estadística es la más apropiada para analizar la relación entre estas dos variables categóricas?

A) Prueba t de Student

B) Prueba Chi-cuadrada de independencia (χ^2)

C) Prueba Z

D) ANOVA (prueba F)

5. Intervalo de confianza

Se seleccionan aleatoriamente 30 estudiantes de una institución educativa y se registran sus calificaciones. Los resultados son:

• Tamaño de la muestra: n = 30

• Media muestral: 80

• Varianza muestral: 9

• Nivel de confianza: 95%

Calcula un intervalo de confianza del 95% para la media poblacional de las calificaciones. Muestra el procedimiento e interpreta el resultado.

Procedimiento e interpretación:

1. **Desviación estándar:** te dan la varianza (9), sacas raíz: s = 3.
2. **Error estándar:** $s / \sqrt{n} = 3 / \sqrt{30} \approx 0.5477$. Mide cuánto suele variar **el promedio** de una muestra a otra. Fíjate que al dividir entre √n, entre más grande la muestra, más chico el error. Tiene sentido: con más datos estimas mejor.
3. **Valor crítico (t):** es un número sacado de tablas que corresponde al 95% de confianza. Se usa la **t de Student** porque no conocemos la σ de toda la población, solo la de la muestra. Los **grados de libertad** son $n - 1 = 29$, y con eso la tabla da 2.045. (Si usaran Z, el número sería 1.96.)
4. **Margen de error:** $2.045 \times 0.5477 \approx 1.12$

5. **Intervalo:** 80 − 1.12 = 78.88 y 80 + 1.12 = 81.12 → **(78.88, 81.12)**

Interpretación: Con esto concluyo que, con un 95 % de confianza, el promedio real de las calificaciones de todos los estudiantes de la institución está entre 78.88 y 81.12. Lo entiendo así: si repitiera el muestreo muchas veces, el 95 % de los intervalos que calculara de esta forma contendrían la media real.

6. Correlación de variables utilizando Python

Utiliza el conjunto de datos load_breast_cancer de Scikit-learn para identificar qué característica tiene la correlación lineal más fuerte (positiva o negativa) con la variable objetivo target.

Código de partida:

```
import numpy as np
import pandas as pd
from sklearn.datasets import load_breast_cancer

# Cargar los datos
data = load_breast_cancer()
# Crear un DataFrame
df = pd.DataFrame(data.data, columns=data.feature_names)
# Agregar la variable objetivo
df["target"] = 1 - data.target
```

Mi código en Jupyter:

```python
import numpy as np
import pandas as pd
from sklearn.datasets import load_breast_cancer

# Cargar los datos
data = load_breast_cancer()

# Crear un DataFrame
df = pd.DataFrame(data.data, columns=data.feature_names)

# Agregar la variable objetivo (se invierte: 1 = maligno, 0 = benigno)
df["target"] = 1 - data.target

df.head()
```

	mean radius	mean texture	mean perimeter	mean area	mean smoothness	mean compactness	mean concavity	mean concave points	mean symmetry	mean fractal dimension	...	worst texture	p
0	17.99	10.38	122.80	1001.0	0.11840	0.27760	0.3001	0.14710	0.2419	0.07871	...	17.33	
1	20.57	17.77	132.90	1326.0	0.08474	0.07864	0.0869	0.07017	0.1812	0.05667	...	23.41	
2	19.69	21.25	130.00	1203.0	0.10960	0.15990	0.1974	0.12790	0.2069	0.05999	...	25.53	
3	11.42	20.38	77.58	386.1	0.14250	0.28390	0.2414	0.10520	0.2597	0.09744	...	26.50	
4	20.29	14.34	135.10	1297.0	0.10030	0.13280	0.1980	0.10430	0.1809	0.05883	...	16.67	

5 rows × 31 columns

Actividades:

a) Calcula la correlación de Pearson entre cada característica y la variable target.

```
# corr() usa Pearson por defecto; nos quedamos con la columna de target
correlaciones = df.corr()["target"]
correlaciones
```

```
mean radius                0.730029
mean texture               0.415185
mean perimeter             0.742636
mean area                  0.708984
mean smoothness            0.358560
mean compactness           0.596534
mean concavity             0.696360
mean concave points        0.776614
mean symmetry              0.330499
mean fractal dimension    -0.012838
radius error               0.567134
texture error             -0.008303
perimeter error            0.556141
area error                 0.548236
smoothness error          -0.067016
compactness error          0.292999
concavity error            0.253730
concave points error       0.408042
symmetry error            -0.006522
fractal dimension error    0.077972
worst radius               0.776454
worst texture              0.456903
worst perimeter            0.782914
worst area                 0.733825
worst smoothness           0.421465
worst compactness          0.590998
worst concavity            0.659610
worst concave points       0.793566
worst symmetry             0.416294
worst fractal dimension    0.323872
target                     1.000000
Name: target, dtype: float64
```

Respuesta: Usé df.corr(), que calcula la correlación de Pearson entre todas las columnas, y me quedé con la columna de target para ver qué tan relacionada está cada característica con el diagnóstico.

b) Identifica la característica con mayor correlación en valor absoluto, excluyendo la correlación de target consigo misma.

```
# Quitamos target (su correlación consigo misma siempre es 1)
correlaciones = correlaciones.drop("target")

# abs() quita el signo para comparar la fuerza, sin importar si es positiva o negativa
correlaciones.abs().sort_values(ascending=False).head(5)
```

```
worst concave points    0.793566
worst perimeter         0.782914
mean concave points     0.776614
worst radius            0.776454
mean perimeter          0.742636
Name: target, dtype: float64
```

```
mejor = correlaciones.abs().idxmax()
print("Característica con mayor correlación:", mejor)
print("Correlación:", round(correlaciones[mejor], 3))
```

```
Característica con mayor correlación: worst concave points
Correlación: 0.794
```

Respuesta: Quité target con .drop(), porque su correlación consigo misma siempre es 1, y usé .abs() para comparar la fuerza sin importar el signo. Encontré que la característica con mayor correlación es worst concave points, con 0.794.

c) Indica si su correlación con target es positiva o negativa y explica brevemente qué significa.

```python
if correlaciones[mejor] > 0:
    print("La correlación es positiva")
else:
    print("La correlación es negativa")
```

```
La correlación es positiva
```

Respuesta: Obtuve una correlación positiva. Como en el código de partida se usa target = 1 − data.target, tomé en cuenta que aquí 1 significa tumor maligno y 0 benigno. Por eso interpreto que, entre más puntos cóncavos tiene el contorno de la célula, más probable es que el tumor sea maligno.

Escribe tu conclusión:

Concluyo que la característica con la correlación lineal más fuerte con target es worst concave points (0.794), y que la relación es positiva: valores más altos de puntos cóncavos se asocian con tumores malignos. También noté que le siguen worst perimeter (0.783), mean concave points (0.777) y worst radius (0.776), así que las medidas de tamaño y de forma irregular de las células son las que más se relacionan con el diagnóstico. Un valor cercano a 0.8 me indica una relación lineal fuerte, aunque tengo presente que la correlación por sí sola no demuestra que una variable cause la otra.